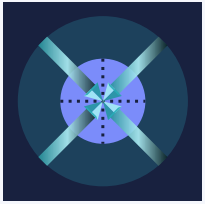
DATA SCIENCE / CUSTOMER ANALYTICS



Analyse und Vorhersage von Kundenabwanderung

Explorative Merkmalsanalyse und logistische Regression

A. Ebrahimi, H. Abdo

BBQ - Online / PCED - 101

27. Oktober 2026

Überblick

01 THEMA

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

02 ZIEL

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

02 ZIEL

Zusammenhänge untersuchen und ein erstes Vorhersagemodell aufbauen.

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

02 ZIEL

Zusammenhänge untersuchen und ein erstes Vorhersagemodell aufbauen.

03 DATEN

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

02 ZIEL

Zusammenhänge untersuchen und ein erstes Vorhersagemodell aufbauen.

03 DATEN

IBM Telco Customer Churn: **7 043** Datensätze ▪ **21** Spalten

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

02 ZIEL

Zusammenhänge untersuchen und ein erstes Vorhersagemodell aufbauen.

03 DATEN

IBM Telco Customer Churn: **7 043** Datensätze ▪ **21** Spalten

04 VORGEHEN

Überblick

01 THEMA

Kundenabwanderung (Churn) bei einem Telekommunikationsanbieter.

02 ZIEL

Zusammenhänge untersuchen und ein erstes Vorhersagemodell aufbauen.

03 DATEN

IBM Telco Customer Churn: **7 043** Datensätze ▪ **21** Spalten

04 VORGEHEN

Bereinigung, Feature-Analyse, Kodierung und logistische Regression.

Fragestellung und Zielvariable

- Zielvariable ist `Churn`: Kündigung $= 1$, keine Kündigung $= 0$.

Fragestellung und Zielvariable

- Zielvariable ist `Churn`: Kündigung $= 1$, keine Kündigung $= 0$.
- Es werden Kunden-, Vertrags- und Dienstleistungsmerkmale betrachtet.

Fragestellung und Zielvariable

- Zielvariable ist `Churn`: Kündigung = 1, keine Kündigung = 0.
- Es werden Kunden-, Vertrags- und Dienstleistungsmerkmale betrachtet.
- Der Churn-Anteil nach der Bereinigung beträgt rund 26,6 %; etwa 73,4 % bleiben.

Fragestellung und Zielvariable

- Zielvariable ist `Churn`: Kündigung = 1, keine Kündigung = 0.
- Es werden Kunden-, Vertrags- und Dienstleistungsmerkmale betrachtet.
- Der Churn-Anteil nach der Bereinigung beträgt rund 26,6 %; etwa 73,4 % bleiben.
- Die Analyse soll relevante Merkmale sichtbar machen und die Vorhersage auf unbekannten Daten prüfen.

Strategie / Analysepipeline

1

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).
5.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).
5. Daten stratifiziert in Training (80 %) und Test (20 %) teilen.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).
5. Daten stratifiziert in Training (80 %) und Test (20 %) teilen.
6.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).
5. Daten stratifiziert in Training (80 %) und Test (20 %) teilen.
6. Numerische Merkmale skalieren und logistische Regression trainieren.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).
5. Daten stratifiziert in Training (80 %) und Test (20 %) teilen.
6. Numerische Merkmale skalieren und logistische Regression trainieren.
7.

Strategie / Analysepipeline

1. Datensatz laden und Duplikate bzw. fehlende Werte prüfen.
2. Identifikator `customerID` entfernen und `TotalCharges` numerisch konvertieren.
3. Merkmale explorativ vergleichen: Spannweite der Churn-Raten, Chi-Quadrat-Test und Phi-Koeffizient.
4. Merkmale auswählen und kategoriale Variablen kodieren (One-Hot-Encoding).
5. Daten stratifiziert in Training (80 %) und Test (20 %) teilen.
6. Numerische Merkmale skalieren und logistische Regression trainieren.
7. Güte mit Accuracy, ROC-AUC, Konfusionsmatrix sowie Precision/Recall/F1 bewerten.

Datenaufbereitung

- **Ausgangsdaten:**

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:**

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.
- **Erklärende Merkmale:**

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.
- **Erklärende Merkmale:** `customerID`:wird nicht als erklärendes Merkmal verwendet.

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.
- **Erklärende Merkmale:** `customerID`:wird nicht als erklärendes Merkmal verwendet.
- **Encoding:**

.

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.
- **Erklärende Merkmale:** `customerID`:wird nicht als erklärendes Merkmal verwendet.
- **Encoding:** Kategoriale Merkmale werden numerisch kodiert; bei One-Hot-Encoding wird eine Referenzkategorie weggelassen.

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.
- **Erklärende Merkmale:** `customerID`:wird nicht als erklärendes Merkmal verwendet.
- **Encoding:** Kategoriale Merkmale werden numerisch kodiert; bei One-Hot-Encoding wird eine Referenzkategorie weggelassen.
- **Standardisierung:**

Datenaufbereitung

- **Ausgangsdaten:** 7 043 Zeilen, 21 Spalten.
- **Markmale Untersuchungen:** Nach Entfernung des Identifikators und Bereinigung: 7 032 Zeilen; 11 nicht numerisch interpretierbare `TotalCharges`-Werte wurden zu fehlenden Werten und anschließend entfernt.
- **Erklärende Merkmale:** `customerID`:wird nicht als erklärendes Merkmal verwendet.
- **Encoding:** Kategoriale Merkmale werden numerisch kodiert; bei One-Hot-Encoding wird eine Referenzkategorie weggelassen.
- **Standardisierung:**Für die logistische Regression werden `tenure` und `MonthlyCharges` standardisiert.

Strategie der Merkmalsanalyse

- **Feature Screening:**

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:**

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.
- **Phi-Koeffizient:**

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.
- **Phi-Koeffizient:** Beschreibt die Stärke des Zusammenhangs für geeignete binäre Variablen.

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.
- **Phi-Koeffizient:** Beschreibt die Stärke des Zusammenhangs für geeignete binäre Variablen.
- **Signifikanzniveau:**

Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.
- **Phi-Koeffizient:** Beschreibt die Stärke des Zusammenhangs für geeignete binäre Variablen.
- **Signifikanzniveau:** Wir haben das Signifikanzniveau von $\alpha = 0{,}01$ verwendet.

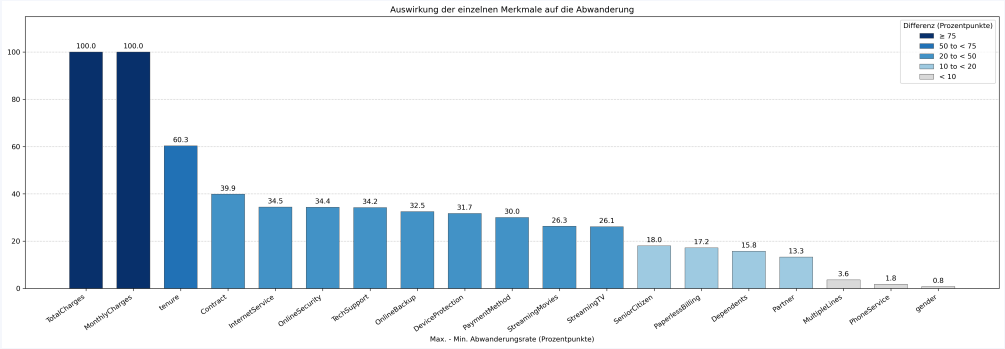
Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.
- **Phi-Koeffizient:** Beschreibt die Stärke des Zusammenhangs für geeignete binäre Variablen.
- **Signifikanzniveau:** Wir haben das Signifikanzniveau von $\alpha = 0{,}01$ verwendet.
- **Interpretation mit Vorsicht:**

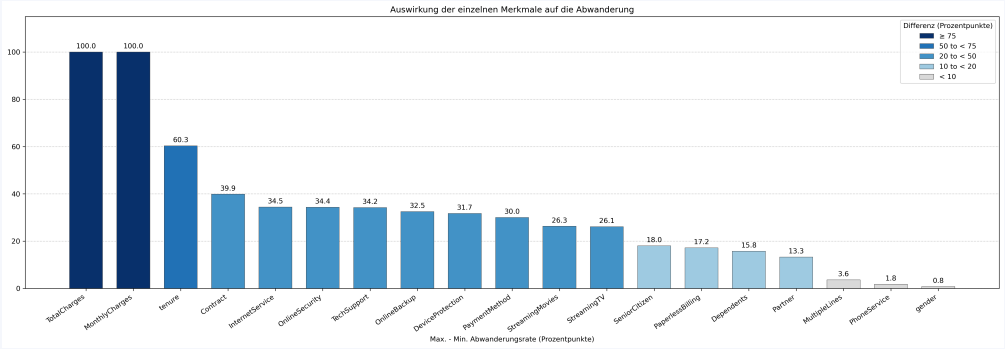
Strategie der Merkmalsanalyse

- **Feature Screening:** Differenz zwischen höchster und niedrigster Churn-Rate je Merkmal.
- **Chi-Quadrat-Test:** Prüft, ob kategoriale Merkmale und Churn statistisch zusammenhängen.
- **Phi-Koeffizient:** Beschreibt die Stärke des Zusammenhangs für geeignete binäre Variablen.
- **Signifikanzniveau:** Wir haben das Signifikanzniveau von $\alpha = 0{,}01$ verwendet.
- **Interpretation mit Vorsicht:** `MonthlyCharges` benötigt besondere Aufmerksamkeit; Zusammenhang bedeutet nicht automatisch Kausalität.

Explorative Analyse

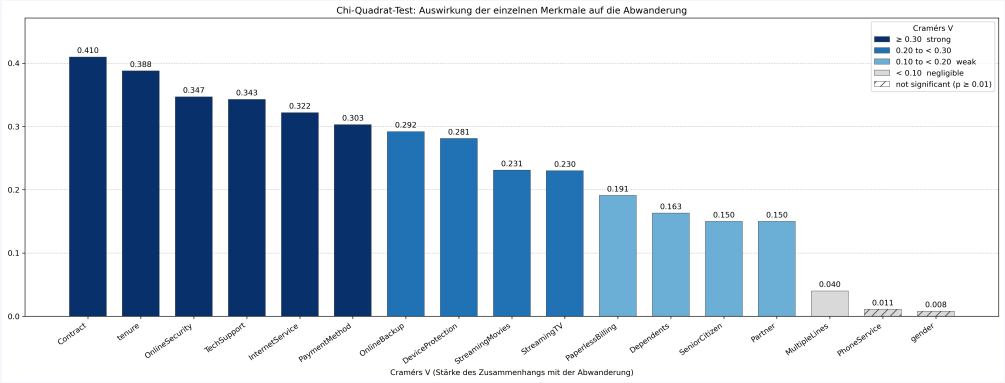


Explorative Analyse

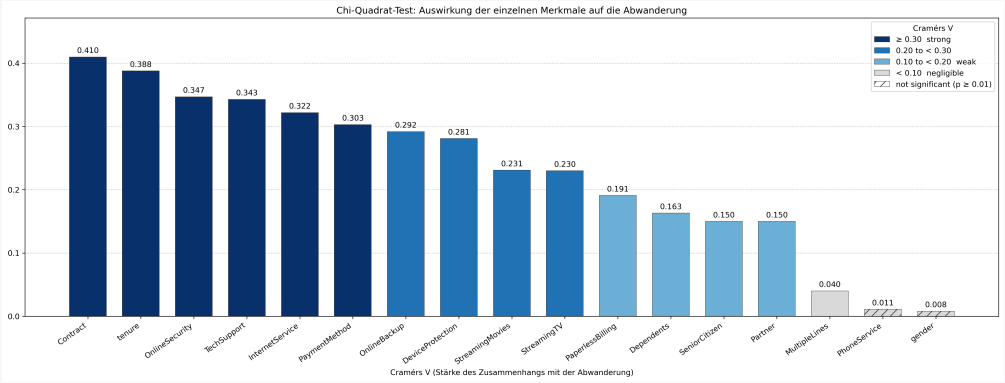


Unterschiede der Churn-Raten nach Merkmalen

Zusammenhang zwischen Merkmalen und Churn



Zusammenhang zwischen Merkmalen und Churn



Chi-Quadrat-Test und Phi-Koeffizient

Zusammenfassung der Merkmalskombinationen

01 CHURN-RATE

Zusammenfassung der Merkmalskombinationen

01 CHURN-RATE

Die zehn stärksten Kombinationen liegen zwischen **52,18 %** und **54,65 %** und damit rund doppelt so hoch wie der Durchschnitt von 26,6 %.

Zusammenfassung der Merkmalskombinationen

01 CHURN-RATE

Die zehn stärksten Kombinationen liegen zwischen **52,18 %** und **54,65 %** und damit rund doppelt so hoch wie der Durchschnitt von 26,6 %.

02 HÄUFIGE MERKMALE

Zusammenfassung der Merkmalskombinationen

01 CHURN-RATE

Die zehn stärksten Kombinationen liegen zwischen **52,18 %** und **54,65 %** und damit rund doppelt so hoch wie der Durchschnitt von 26,6 %.

02 HÄUFIGE MERKMALE

`PaymentMethod_Electronic check` (6 von 10), `Contract_Month-to-month` (4 von 10) und `SeniorCitizen` (3 von 10) kommen am häufigsten vor.

Zusammenfassung der Merkmalskombinationen

01 CHURN-RATE

Die zehn stärksten Kombinationen liegen zwischen **52,18 %** und **54,65 %** und damit rund doppelt so hoch wie der Durchschnitt von 26,6 %.

02 HÄUFIGE MERKMALE

`PaymentMethod_Electronic check` (6 von 10), `Contract_Month-to-month` (4 von 10) und `SeniorCitizen` (3 von 10) kommen am häufigsten vor.

03 EINORDNUNG

Zusammenfassung der Merkmalskombinationen

01 CHURN-RATE

Die zehn stärksten Kombinationen liegen zwischen **52,18 %** und **54,65 %** und damit rund doppelt so hoch wie der Durchschnitt von 26,6 %.

02 HÄUFIGE MERKMALE

`PaymentMethod_Electronic check` (6 von 10), `Contract_Month-to-month` (4 von 10) und `SeniorCitizen` (3 von 10) kommen am häufigsten vor.

03 EINORDNUNG

Jede Kombination umfasst **375** Kunden. Die Zusammenhänge zeigen, welche Gruppen gefährdet sind, belegen aber keine Kausalität.

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37
6	InternetService_Fiber optic mit PaymentMethod_Electronic check	1595	53.23

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37
6	InternetService_Fiber optic mit PaymentMethod_Electronic check	1595	53.23
7	TechSupport_No mit PaymentMethod_Electronic check	1730	53.18

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37
6	InternetService_Fiber optic mit PaymentMethod_Electronic check	1595	53.23
7	TechSupport_No mit PaymentMethod_Electronic check	1730	53.18
8	OnlineSecurity_No mit PaymentMethod_Electronic check	1734	53.17

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37
6	InternetService_Fiber optic mit PaymentMethod_Electronic check	1595	53.23
7	TechSupport_No mit PaymentMethod_Electronic check	1730	53.18
8	OnlineSecurity_No mit PaymentMethod_Electronic check	1734	53.17
9	SeniorCitizen mit OnlineBackup_No	614	52.77

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37
6	InternetService_Fiber optic mit PaymentMethod_Electronic check	1595	53.23
7	TechSupport_No mit PaymentMethod_Electronic check	1730	53.18
8	OnlineSecurity_No mit PaymentMethod_Electronic check	1734	53.17
9	SeniorCitizen mit OnlineBackup_No	614	52.77
10	MonthlyCharges mit Contract_Month-to-month	870	52.18

Merkmalskombinationen mit hoher Churn-Rate

#	Kombination von zwei Merkmalen	Kundenanzahl	Churn-Rate
1	SeniorCitizen mit Contract_Month-to-month	807	54.65
2	InternetService_Fiber optic mit Contract_Month-to-month	2128	54.61
3	OnlineBackup_No mit PaymentMethod_Electronic check	1428	53.92
4	Contract_Month-to-month mit PaymentMethod_Electronic check	1850	53.73
5	SeniorCitizen mit PaymentMethod_Electronic check	594	53.37
6	InternetService_Fiber optic mit PaymentMethod_Electronic check	1595	53.23
7	TechSupport_No mit PaymentMethod_Electronic check	1730	53.18
8	OnlineSecurity_No mit PaymentMethod_Electronic check	1734	53.17
9	SeniorCitizen mit OnlineBackup_No	614	52.77
10	MonthlyCharges mit Contract_Month-to-month	870	52.18

Diese Tabelle zeigt die höchste Churn-Rate aus der Kombination zweier Merkmale, die Anzahl der Kunden sowie die Churn-Rate.

Modellaufbau

- **Modell:**

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.
- **Aufteilung:**

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.
- **Aufteilung:** 80 % Trainingsdaten und 20 % Testdaten, mit `stratify=y` und `random_state=42`.

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.
- **Aufteilung:** 80 % Trainingsdaten und 20 % Testdaten, mit `stratify=y` und `random_state=42`.
- **Trainingsdaten:**

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.
- **Aufteilung:** 80 % Trainingsdaten und 20 % Testdaten, mit `stratify=y` und `random_state=42`.
- **Trainingsdaten:** Die Vorverarbeitung wird anhand der Trainingsdaten angepasst; dieselbe Skalierung wird auf den Testdaten angewendet.

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.
- **Aufteilung:** 80 % Trainingsdaten und 20 % Testdaten, mit `stratify=y` und `random_state=42`.
- **Trainingsdaten:** Die Vorverarbeitung wird anhand der Trainingsdaten angepasst; dieselbe Skalierung wird auf den Testdaten angewendet.
- **Was liefert das Modell:**

Modellaufbau

- **Modell:** logistische Regression aus `scikit-learn`.
- **Aufteilung:** 80 % Trainingsdaten und 20 % Testdaten, mit `stratify=y` und `random_state=42`.
- **Trainingsdaten:** Die Vorverarbeitung wird anhand der Trainingsdaten angepasst; dieselbe Skalierung wird auf den Testdaten angewendet.
- **Was liefert das Modell:** Das Modell liefert sowohl Klassenprognosen als auch geschätzte Churn-Wahrscheinlichkeiten.

Ergebnisse auf dem Testdatensatz

ACCURACY

78,75 %

Ergebnisse auf dem Testdatensatz

ACCURACY
78,75 %

ROC-AUC
0,830

Ergebnisse auf dem Testdatensatz

ACCURACY
78,75 %

ROC-AUC
0,830

RECALL · CHURN
0,53

Ergebnisse auf dem Testdatensatz

ACCURACY
78,75 %

ROC-AUC
0,830

RECALL · CHURN
0,53

Metrik	Ergebnis
Precision (Churn = 1)	0,62
F1-Score (Churn = 1)	0,57

Ergebnisse auf dem Testdatensatz

ACCURACY
78,75 %

ROC-AUC
0,830

RECALL · CHURN
0,53

Metrik	Ergebnis
Precision (Churn = 1)	0,62
F1-Score (Churn = 1)	0,57

Das Modell erkennt einen Teil der kündigenden Kunden, verpasst beim Schwellenwert 0,5 jedoch noch viele. Accuracy allein reicht daher nicht aus; Recall und Fehlklassifikationskosten sind ebenfalls wichtig.

Konfusionsmatrix und Einordnung

	Prognose: bleibt	**Prognose: kündigt**
Tatsächlich: bleibt	911	122
Tatsächlich: kündigt	177	197

Konfusionsmatrix und Einordnung

	Prognose: bleibt	**Prognose: kündigt**
Tatsächlich: bleibt	911	122
Tatsächlich: kündigt	177	197

- 197 von 374 tatsächlichen Kündigungen wurden erkannt.

Konfusionsmatrix und Einordnung

	Prognose: bleibt	**Prognose: kündigt**
Tatsächlich: bleibt	911	122
Tatsächlich: kündigt	177	197

- 197 von 374 tatsächlichen Kündigungen wurden erkannt.
- 177 Kündigungen wurden übersehen; eine mögliche nächste Verbesserung ist die Prüfung des Entscheidungsschwellenwerts.

Konfusionsmatrix und Einordnung

	Prognose: bleibt	Prognose: kündigt
Tatsächlich: bleibt	911	122
Tatsächlich: kündigt	177	197

- 197 von 374 tatsächlichen Kündigungen wurden erkannt.
- 177 Kündigungen wurden übersehen; eine mögliche nächste Verbesserung ist die Prüfung des Entscheidungsschwellenwerts.
- Im Notebook wird außerdem starke Multikollinearität bei einigen One-Hot-Spalten gemeldet. Das sollte vor einer Koeffizienteninterpretation geprüft werden.

Fazit und nächste Schritte

KERNAUSSAGE

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

- Multikollinearität reduzieren und Koeffizienten sorgfältig interpretieren.

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

- Multikollinearität reduzieren und Koeffizienten sorgfältig interpretieren.
-

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

- Multikollinearität reduzieren und Koeffizienten sorgfältig interpretieren.
- Weitere Modelle vergleichen und Cross-Validation durchführen.

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

- Multikollinearität reduzieren und Koeffizienten sorgfältig interpretieren.
- Weitere Modelle vergleichen und Cross-Validation durchführen.
-

Fazit und nächste Schritte

KERNAUSSAGE

Die Pipeline liefert ein erstes brauchbares Basismodell: 78,7 % Accuracy und 0,83 ROC-AUC. Die Erkennung kündigender Kunden bleibt mit einem Recall von 0,53 ausbaufähig.

Nächste Schritte

- Multikollinearität reduzieren und Koeffizienten sorgfältig interpretieren.
- Weitere Modelle vergleichen und Cross-Validation durchführen.
- Entscheidungsschwellenwert an den Geschäftszielen und den Kosten von Fehlklassifikationen ausrichten.

Vielen Dank

DANKE

Vielen Dank

DANKE

Vielen Dank für Ihre Aufmerksamkeit!

Vielen Dank

DANKE

Vielen Dank für Ihre Aufmerksamkeit!

FRAGEN

Vielen Dank

DANKE

Vielen Dank für Ihre Aufmerksamkeit!

FRAGEN

Gibt es Fragen oder Anmerkungen?